

Introducción a los Modelos Multivariados

Sesión 6: Fundamentos, Repaso Estadístico y Regresión Lineal Múltiple

Gabriel Sotomayor

2025-04-21



Objetivos de la Sesión

En esta (potencialmente larga) sesión, construiremos las bases para el análisis multivariado:

1. **Entender** por qué usamos **modelos multivariados** en sociología y sus funciones principales.
2. **Diferenciar** entre enfoques **exploratorios** y **confirmatorios**, y entre modelos de **medición** y **relacionales**.
3. **Repasar** conceptos estadísticos clave: **varianza**, **covarianza**, **correlación** (Pearson y brevemente poli/tetracórica).
4. **Revisitar** la **regresión lineal múltiple (RLM)**, enfatizando el **control estadístico** y la interpretación de **coeficientes estandarizados**.
5. Comprender la lógica de la **inferencia estadística** en regresión (test de hipótesis sobre coeficientes) y su **importancia** (y limitación con **lm**) en diseños complejos.



Parte I: El Mundo de los Modelos Multivariados



¿Por Qué Modelos Multivariados?

La realidad social es **compleja**. Los fenómenos que estudiamos (desigualdad, movilidad social, opinión pública, comportamiento electoral...) raramente dependen de *una sola* causa.

- **Análisis Bivariado (Correlación, t-test, χ^2):** Útil para explorar relaciones iniciales entre *dos* variables, pero limitado. No captura la red de influencias simultáneas.
- **Modelos Multivariados:** Son nuestra herramienta para representar y analizar sistemas con **múltiples variables interactuando**. Nos permiten:
 - **Describir** relaciones complejas.
 - **Explicar** fenómenos considerando múltiples factores y **controlando** por variables alternativas.
 - **Predecir** resultados con mayor precisión.
 - **Testear** teorías sociológicas que postulan relaciones múltiples.



Funciones de los Modelos en Cs. Sociales

Los modelos multivariados nos sirven para:

1. **Formalizar Teorías:** Traducir ideas teóricas verbales a relaciones específicas entre variables, permitiendo rigurosidad y testeo empírico.
2. **Identificar Efectos Netos:** Aislar el impacto de una variable de interés sobre otra, eliminando estadísticamente la influencia de terceras variables (control estadístico).
¿Cuál es el efecto “puro” de la educación sobre el ingreso, una vez que consideramos la experiencia laboral y el origen socioeconómico?
3. **Descubrir Estructuras Subyacentes:** Encontrar patrones ocultos o dimensiones latentes en conjuntos grandes de variables (Ej: ¿Qué dimensiones básicas explican las respuestas a una batería de preguntas sobre actitudes políticas?).
4. **Evaluar Ajuste Teoría-Datos:** Determinar si un modelo teórico propuesto es compatible con los datos observados.



Un Mapa para Navegar los Modelos

Podemos organizar los modelos que veremos en el curso (y otros) según dos ejes principales:

Eje 1: ¿Exploramos o Confirmamos?

- **Modelos Exploratorios:** ¿Qué nos dicen los datos? Buscamos patrones sin una hipótesis fuerte *a priori*.
- **Modelos Confirmatorios:** ¿Se ajustan los datos a mi teoría? Testeamos una estructura hipotetizada previamente.

Eje 2: ¿Medimos Conceptos o Relacionamos Variables?

- **Modelos de Medición:** ¿Cómo se relacionan los indicadores observables con un concepto latente?
- **Modelos Relacionales (o Estructurales):** ¿Cómo se relacionan distintas variables (observadas o latentes) entre sí?



Eje 1: Exploratorio vs. Confirmatorio

- **Análisis Factorial Exploratorio (AFE):**
 - **Objetivo:** Identificar factores o dimensiones latentes comunes que explican las correlaciones entre un conjunto de variables observadas (ítems de una escala, indicadores).
 - **Pregunta:** ¿Cuántas dimensiones subyacen a estos 20 ítems sobre bienestar? ¿Qué ítems cargan en qué dimensión?
 - **Naturaleza:** Guiado por los datos, busca descubrir estructura.



Eje 1: Exploratorio vs. Confirmatorio

- **Análisis Factorial Confirmatorio (AFC), Análisis de Senderos, Modelos de Ecuaciones Estructurales (SEM):**
 - **Objetivo:** Testear si una estructura de relaciones (entre ítems y factores, o entre diferentes factores/variables) definida *previamente* por la teoría se ajusta bien a los datos observados.
 - **Pregunta:** ¿Confirman los datos que la “autoeficacia” (medida por 4 ítems) predice el “rendimiento académico” (medido por notas), controlando por “apoyo familiar” (medido por 3 ítems)?
 - **Naturaleza:** Guiado por la teoría, busca validar un modelo específico.



Eje 2: Medición vs. Relacional

- **Modelos de Medición:**
 - Se enfocan en la **calidad de la medición**. ¿Son fiables y válidos nuestros indicadores para medir el concepto abstracto que nos interesa?
 - Central en **AFC** (¿qué miden los factores?) y **AFC** (¿miden bien los ítems el factor que *creemos* que miden?).
- **Modelos Relacionales / Estructurales:**
 - Se enfocan en las **relaciones entre variables** (sean observadas o latentes).
 - **Regresión Lineal Múltiple (RLM):** Relaciona variables observadas.
 - **Análisis de Senderos:** Modela relaciones causales hipotetizadas entre variables *observadas*.
 - **Modelos de Ecuaciones Estructurales (SEM):** El más general. Modela relaciones entre variables *latentes* y/o *observadas*, combinando modelos de medición y modelos relacionales.

(Estos ejes no son excluyentes, SEM por ejemplo, incluye ambos tipos de modelos).



Parte II: Repaso de Conceptos Estadísticos Clave



Variabilidad y Dispersión

Recordatorio rápido: Para entender relaciones, primero necesitamos entender cómo varían las variables por sí solas.

- **Varianza (s^2):** Promedio de las distancias al cuadrado de cada dato respecto a la media. Mide la dispersión total, pero en unidades al cuadrado (difícil interpretación directa).

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$$

- **Desviación Estándar (s):** Raíz cuadrada de la varianza. Vuelve a las unidades originales de la variable. Es la medida de dispersión más usada e interpretable.

$$s = \sqrt{s^2}$$

Mayor s -> Mayor heterogeneidad / dispersión.



Co-Variación: Covarianza y Correlación

¿Cómo varían *dos variables juntas*?

- **Covarianza:** Mide la dirección de la relación lineal entre dos variables.

$$Cov(x, y) = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

- Signo (+): Relación directa (si X sube, Y tiende a subir).
- Signo (-): Relación inversa (si X sube, Y tiende a bajar).
- **Problema:** Su magnitud depende de las escalas de X e Y. No permite comparar fuerza de asociación entre distintos pares de variables.



Co-Variación: Covarianza y Correlación

- **Correlación de Pearson (r):** La covarianza estandarizada.


$$r = \frac{Cov(x, y)}{s_x s_y}$$

- Varía entre -1 y +1.
- **+1:** Correlación lineal positiva perfecta.
- **-1:** Correlación lineal negativa perfecta.
- **0:** Ausencia de correlación *lineal*.
- **Ventaja:** Adimensional, permite comparar la *fuerza* de la relación lineal.
- **Limitación Central: Sólo mide relaciones LINEALES.** Una correlación de 0 no significa que no haya *ninguna* relación (podría ser curvilínea).




Graficos de dispersión y correlación


Correlación $r = 0$




Correlación $r = 0.5$




Correlación $r = 0.9$




Correlación $r = -0.3$



Correlación $r = -0.7$



Correlación $r = -0.99$



Correlaciones para Datos No Continuos

¿Qué hacemos si nuestras variables son **ordinales** (ej. escalas Likert: “Muy en desacuerdo” a “Muy de acuerdo”) o **dicotómicas** (ej. Sí/No, Hombre/Mujer)? Pearson no es ideal.

Idea Clave: Suponer que detrás de la variable categórica observada existe una **variable latente continua** (no observable) que sigue una distribución normal. Lo que observamos son “cortes” en esa distribución latente.

- **Correlación Policórica:** Estima la correlación entre las *variables latentes continuas* asumidas detrás de dos variables **ordinales**.
- **Correlación Tetracórica:** Estima la correlación entre las *variables latentes continuas* asumidas detrás de dos variables **dicotómicas**.



Correlaciones para Datos No Continuos

¿Por qué son importantes?

- * El **Análisis Factorial (AFE/AFC)** se basa en analizar la **matriz de correlaciones** entre las variables.
- * Si tenemos variables ordinales o dicotómicas, usar la matriz de correlaciones de Pearson puede distorsionar los resultados del AFE/AFC. Es **más adecuado** usar una matriz de correlaciones policóricas/tetracóricas (o mixtas).

*(En R, el paquete **polycor** permite calcularlas).*



Parte III: De la Correlación a la Regresión Lineal



Más Allá de la Asociación: Regresión Lineal Simple (RLS)

La correlación nos dice *si* y *cómo* X e Y varían juntas linealmente. La **Regresión Lineal Simple** va un paso más allá: intenta **modelar** esa relación y **predecir** el valor de la variable dependiente (Y) a partir de la variable independiente (X) usando una **línea recta**.

Ecuación de la Recta de Regresión:


$$\hat{y} = a + bx$$

- $\hat{y}$: Es el valor de Y **predicho** por el modelo para un valor dado de X.
- a : Es el **intercepto** (o constante). Representa el valor predicho de Y cuando X es igual a 0. Su interpretación práctica depende de si $X=0$ tiene sentido en el contexto del problema.
- b : Es la **pendiente** (o coeficiente de regresión). Indica el **cambio promedio estimado** en Y por cada **incremento de una unidad** en X. Es la medida clave del efecto de X sobre Y en este modelo.



Visualizando la RLS

La recta de regresión busca ser la línea que “mejor representa” la tendencia lineal en la nube de puntos de un diagrama de dispersión. La recta resume la relación lineal promedio.



¿Cómo Encontrar la “Mejor” Recta?

Mínimos Cuadrados (OLS)

Hay infinitas rectas posibles. OLS (Ordinary Least Squares) es el método estándar para elegir la “mejor”:

- **Residuo (e_i):** Para cada punto (x_i, y_i) , es la diferencia vertical entre el valor *observado* y_i y el valor *predicho* por la recta $\hat{y}_i$.


$$e_i = y_i - \hat{y}_i = y_i - (a + bx_i)$$

- El residuo es el **error de predicción** del modelo para esa observación.
- OLS busca la recta (los valores de a y b) que minimiza la SUMA de los CUADRADOS de todos los residuos:

$$\text{Minimizar } \sum e_i^2 = \sum (y_i - \hat{y}_i)^2$$



Visualización de la distancia entre la recta y los casos



Fórmulas para OLS (RLS)

Para calcular la pendiente b y la ordenada en el origen a , se utilizan las siguientes fórmulas:

$$b = r \frac{s_y}{s_x}$$

$$a = \bar{y} - b\bar{x}$$

Donde:

r es la correlación entre x y y .

s_x y s_y son las desviaciones estándar de x y y .

$\bar{x}$ y $\bar{y}$ son las medias de x y y , respectivamente.



Análisis de Residuos: Evaluando el Ajuste del Modelo

Una vez ajustada la recta, **analizar los residuos** es crucial para ver si el modelo lineal es apropiado.






Interpretando el Gráfico de Residuos

¿Qué buscamos en el gráfico de residuos vs. predichos?

- **Ideal (Buen Ajuste):** Una nube de puntos **dispersa aleatoriamente** alrededor de la línea horizontal en 0, sin patrones claros. Esto indica **homocedasticidad** (la varianza del error es constante).
- **Problemas (Mal Ajuste Lineal):**
 - **Patrón Curvo:** Sugiere que la relación entre X e Y **no es lineal**. Un modelo lineal no es adecuado.
 - **Forma de Embudo (Heterocedasticidad):** La dispersión de los residuos aumenta (o disminuye) a medida que aumentan los valores predichos. Viola el supuesto de varianza constante del error. Las predicciones son menos fiables para ciertos rangos de Y.



Diagramas de residuos



Bondad de Ajuste: Coeficiente de Determinación (R^2)

¿Qué **proporción de la variabilidad** total de Y es “explicada” por nuestra recta de regresión basada en X?

- **Descomposición de la Varianza:** La varianza total de Y (SST - Sum of Squares Total) se puede descomponer en:
 - Varianza Explicada por la Regresión (SSR - Sum of Squares Regression).
 - Varianza No Explicada o Residual (SSE - Sum of Squares Error).

$$SST = SSR + SSE$$

$$\sum (y_i - \bar{y})^2 = \sum (\hat{y}_i - \bar{y})^2 + \sum (y_i - \hat{y}_i)^2$$



Bondad de Ajuste: Coeficiente de Determinación (R^2)

- R^2 : Es la proporción de la varianza total que es explicada por el modelo.

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

- Varía entre 0 y 1. Un R^2 de 0.13 indica que el 13% de la varianza en Y está asociada linealmente con X.



Limitaciones de RLS y la Necesidad de RLM

La Regresión Lineal Simple es un buen punto de partida, pero asume que **solo X** influye en Y (o que otros factores no están correlacionados con X). En ciencias sociales, esto es **raramente cierto**.

Problema Central: El coeficiente b de RLS puede capturar no solo el efecto de X, sino también **efectos espurios** o **confundidos** por otras variables omitidas ($Z_1, Z_2, \dots$).

Ejemplo Clásico: Número de bomberos en un incendio (X) y daños causados (Y). RLS mostrará una correlación positiva ($b > 0$). ¿Significa que los bomberos *causan* daño? No, la variable omitida es la **magnitud del incendio (Z)**, que afecta a ambos.

Necesitamos incluir múltiples predictores para controlar estos efectos.



Regresión Lineal Múltiple (RLM): El Poder del Control

RLM: Modela Y en función de **varios predictores** ($X_1, X_2, \dots, X_k$) simultáneamente.

$$Y = b_0 + b_1 X_1 + b_2 X_2 + \dots + b_k X_k + \epsilon$$

Concepto Clave: Control Estadístico

- * La RLM nos permite estimar el efecto de X_1 sobre Y , **como si mantuviéramos constantes** los valores de $X_2, \dots, X_k$.
- * Es un **ajuste matemático** para aislar la asociación única de cada predictor con Y , eliminando la influencia compartida (correlación) entre los predictores.
- * Fundamental en **estudios observacionales** (como encuestas) donde no podemos hacer asignación aleatoria experimental.



Interpretando Coeficientes Parciales en RLM (b_j)

El b_j en RLM es un **coeficiente de regresión parcial**. Su interpretación **SIEMPRE** incluye la cláusula “controlando por las demás variables”:

- b_j representa el cambio *promedio estimado* en Y por cada *unidad de aumento* en X_j , *manteniendo constantes todas las demás variables X incluidas en el modelo*.

Ejemplo: Ingreso = $b_0 + b_1$ Escolaridad (años) + b_2 Edad (años)\$.

* $b_1 = 88000$: Por cada año *adicional* de escolaridad, el ingreso *aumenta en promedio* \$88.000, **para personas de la misma edad**.

* $b_2 = 7600$: Por cada año *adicional* de edad, el ingreso *aumenta en promedio* \$7600, **para personas con la misma escolaridad**.

Diferencia con RLS: El efecto ahora es “neto” de la influencia de las otras variables en el modelo.



Predictores Categóricos en RLM: Variables Dummy

¿Cómo incluir variables como “Sexo” o “Nivel Educativo”?

- **Dicotómicas (0/1):** (Ej: Mujer=0, Hombre=1)
 - Se incluyen directamente.
 - El b asociado es la **diferencia promedio en Y** entre el grupo 1 (Hombre) y el grupo 0 (Mujer, la referencia), controlando por las otras X.



Predictores Categóricos en RLM: Variables Dummy

- **Politómicas (k categorías):** (Ej: Nivel Ed: Básico/Medio/Superior)
 - Se crean **k-1 variables dummy**. Una categoría se deja como **referencia** (Ej: Básico).
 - Dummy Medio: 1 si Ed=Media, 0 si no.
 - Dummy Superior: 1 si Ed=Superior, 0 si no.
 - El modelo sería:
$$Y = b_0 + \dots + b_{medio} \times Dummy_{Medio} + b_{superior} \times Dummy_{Superior}$$
 - b_{medio} : Diferencia promedio en Y entre Ed. Media y Ed. Básica (ref.), controlando por otras X.
 - $b_{superior}$: Diferencia promedio en Y entre Ed. Superior y Ed. Básica (ref.), controlando por otras X.

(R con *factor()* lo hace automáticamente, eligiendo una referencia).



Comparando Efectos: Coeficientes Estandarizados (β)

Los b_j dependen de las unidades. ¿Cómo comparar si un año más de **edad** tiene un impacto “más fuerte” en el **ingreso** que un año más de **escolaridad**?

Coeficientes Beta Estandarizados (β):

- * Se obtienen estandarizando **todas** las variables (Y y Xs) a Z-scores (media 0, DE 1) **antes** de la regresión.
- * **Interpretación:** Indican cuántas **Desviaciones Estándar (DE)** cambia Y por cada **una DE** de cambio en X_j , controlando por las otras Xs (en DE).
- * **Ventaja:** Adimensionales. Permiten comparar la **magnitud relativa** del efecto de predictores con diferentes unidades. Un β de 0.30 tiene un impacto relativo mayor que un β de 0.15.
- * **Usos:** Identificar predictores más influyentes, comparar resultados entre estudios, base para **Senderos y SEM**.



Ajuste del Modelo RLM: R^2 y R^2 Ajustado

- R^2 Múltiple:

- Proporción de varianza de Y explicada por **TODOS** los predictores $X_1, \dots, X_k$ juntos.
- Igual interpretación (0 a 1), pero ahora refleja el poder explicativo *conjunto*.
- **Problema:** Se infla al añadir variables, incluso si son irrelevantes.

- R^2 Ajustado:

- Corrige el R^2 considerando el **número de predictores (k)** y el **tamaño muestral (n)**.

- $$R^2_{ajustado} = 1 - \left(\frac{(1 - R^2)(n - 1)}{n - k - 1} \right)$$

- **Penaliza** por complejidad innecesaria. Mejor para **comparar modelos** con diferente número de predictores.



Parte IV: Inferencia en Regresión



Inferencia: De la Muestra a la Población

Los b_j son **estimaciones** muestrales de los parámetros poblacionales β_j . Debido al **error muestral**, si tomáramos otra muestra, obtendríamos b_j ligeramente diferentes.

Pregunta Central: ¿El efecto b_j que vemos en nuestra muestra es “real” (estadísticamente significativo) en la población, o podría ser solo ruido muestral? ¿Es β_j (el efecto poblacional) **diferente de cero**, controlando por los demás?



Test de Hipótesis para Coeficientes (b_j)

Para cada b_j (usualmente excluyendo b_0):

- $H_0 : \beta_j = 0$ (No hay efecto parcial de X_j en la población).
- $H_1 : \beta_j \neq 0$ (Sí hay efecto parcial de X_j en la población).

Herramientas de Inferencia:

1. **Error Estándar del Coeficiente** ($SE(b_j)$): Mide la precisión de la estimación b_j . Un SE pequeño indica más confianza.
2. **Estadístico t**: $t = b_j / SE(b_j)$. ¿Cuántos SEs se aleja b_j de 0?
3. **p-valor**: Probabilidad de observar un $|t|$ tan grande o más, si H_0 fuera cierta.



Interpretación y Decisión

Interpretación del p-valor:

* Un p-valor **pequeño** (ej. < 0.05) significa que es **muy improbable** observar un efecto tan grande como b_j si realmente no hubiera efecto en la población ($\beta_j = 0$).

Regla de Decisión (Nivel $\alpha = 0.05$):

* Si p-valor < 0.05 :

* **Rechazamos H_0 .**

* Concluimos que el efecto de X_j es **estadísticamente significativo**. Hay evidencia para afirmar que β_j es distinto de cero.

* Si p-valor ≥ 0.05 :

* **No rechazamos H_0 .**

* **No hay evidencia suficiente** para afirmar que β_j sea distinto de cero. *No* significa que sea exactamente cero, solo que no podemos descartarlo.



Inferencia con muestras complejas

Todo lo anterior sobre inferencia (SE, t, p-valores) calculado con `lm()` en R asume Muestreo Aleatorio Simple.

SI TUS DATOS SON DE UNA ENCUESTA COMPLEJA (CAsEN):

- `lm()` ignora los estratos, conglomerados y pesos.
- Los SE estarán **incorrectos** (generalmente subestimados).
- Los p-valores estarán **incorrectos** (generalmente subestimados).
- **Esto puede llevar a conclusiones falsas sobre la significancia**

Solución: * Usar el objeto de diseño (`survey::svydesign` o `srvyr::as_survey`). * Usar `survey::svyglm()` en lugar de `lm()` o `glm()`. * `svyglm` **SÍ** calcula los SE y p-valores correctamente, considerando el diseño.



Próximos Pasos: El Práctico

En el práctico repasaremos en R con `lm()`:

1. Correlaciones.
2. RLS y RLM con predictores continuos y categóricos.
3. Interpretación de coeficientes crudos y estandarizados.
4. Interpretación de la salida de `summary(lm())`, incluyendo p-valores...
5. Cálculo de regresiones usando muestras complejas.

